

预训练模型进行推理

1 脚本核心功能

1. **加载模型**: 加载 `.onnx` 格式的预训练模型，并初始化ONNX Runtime推理会话，优先尝试使用GPU（CUDA）。
2. **加载输入**: 根据用户设定的初始时间戳，加载对应的地表和高空 `.npy` 文件。
3. **迭代预测**: 执行循环预测。将当前时间点的数据输入模型，得到下一个时间点的预测结果。这个预测结果随即成为再下一个时间点的输入，如此往复。
4. **保存结果**: 将每一步的预测结果保存为新的 `.npy` 文件。

2 关键代码解析 (`inference_gpu_pangu_6h.py`)

2.1 用户配置

这是脚本的“控制面板”，用户在此处定义模型路径、数据路径和预测参数。

```
# ONNX 模型文件路径
onnx_model_path =
r"E:\Project_Collection\2025\WEATHER\PANGU\pre_trained_model\pangu_weather_6.onnx"
# 基础项目目录
base_project_dir =
r"E:\Project_Collection\2025\WEATHER\PANGU\DATA\6h\npy"
# 初始时间场的时间戳字符串（格式：YYYYMMDDTHH）
initial_time_str = "20250604T18"
# 预测的6小时步数
run_steps = 1
```

2.2 初始化推理会话

这是利用GPU进行加速的关键。脚本尝试创建 `CUDAExecutionProvider`，如果成功，则后续计算将在GPU上进行，速度极快；如果失败，则会降级到CPU执行。

```
try:
    print("正在初始化 ONNX Runtime 推理会话 (尝试使用 CUDA)...")
    ort_session = ort.InferenceSession(
        onnx_model_path,
        providers=[('CUDAExecutionProvider',
            cuda_provider_options), 'CPUExecutionProvider']
    )
    if 'CUDAExecutionProvider' in
ort_session.get_providers():
        print("ONNX Runtime 会话成功初始化并使用
CUDAExecutionProvider。")
    else:
        print("警告: CUDAExecutionProvider 不可用或未被选中,
将使用 CPUExecutionProvider。")
except Exception as e:
    # ... 错误处理
```

2.3 执行迭代预测

这是模型“思考”和“预报”的核心循环。

```
for i in range(run_steps):
    # ... (准备时间和文件名)

    # Pangu模型期望的输入名是 'input' (高空) 和
    'input_surface' (地表)
    ort_inputs = {
        'input': current_input_upper,
        'input_surface': current_input_surface
```

```
}

# 运行推理
predicted_upper_all_levels, predicted_surface_all_vars
= ort_session.run(None, ort_inputs)

# ... (保存结果)

# 更新下一次迭代的输入：当前预测成为下一次的输入
current_input_upper = predicted_upper_all_levels
current_input_surface = predicted_surface_all_vars
```